

Especialização em *Data Science* e Estatística Aplicada

Módulo IV – Análise de Dados Longitudinais

Prof. Dr. Márcio Luis Lanfredi Viola

Goiânia, 2025

Conteúdo Programático

- Conceitos Básicos.
- Principais delineamentos para dados longitudinais.
- Modelos lineares gerais para dados longitudinais.
- Modelos lineares generalizados para dados longitudinais.
- Modelos com efeitos aleatórios.
- Aplicações.

Conteúdo - Aula 3

- Modelos lineares gerais para dados longitudinais.
- Modelos com efeitos aleatórios.
- Exemplos.

REVISANDO: PERFIL INDIVIDUAL

O perfil individual de resposta com as m observações referentes à i -ésima unidade amostral, $i = 1, \dots, n_j$, submetida ao j -ésimo tratamento, $j = 1, \dots, p$, é dado por

$$\mathbf{Y}_{ij} = (Y_{ij1}, Y_{ij2}, \dots, Y_{ijm})^T$$

em que Y_{ijk} denota o valor da variável resposta para a i -ésima unidade amostral submetida ao j -ésimo tratamento no k -ésimo instante, $k = 1, \dots, m$.

REVISANDO: PERFIS MÉDIOS

Os perfis médios de respostas nos m níveis da condição de avaliação são dados por

$$E(\mathbf{Y}_{ij}) = \boldsymbol{\mu}_j = (\mu_{j1}, \dots, \mu_{jm})^T, j = 1, \dots, p.$$

Como analisar dados longitudinais?

- **Modelo Marginal:** Modela separadamente a média e a estrutura de covariância;
- **Modelo Condicional ou de Efeitos Aleatórios:** Trata os coeficientes como sendo aleatórios para as covariáveis que mudam no tempo (por exemplo, intercepto e coeficiente do tempo).
 - As diferenças entre os perfis surgem porque os coeficientes de regressão variam entre indivíduos;
 - A correlação entre as medidas no mesmo indivíduo são induzidas pelos efeitos aleatórios.

Efeitos

- **Efeito transversal:** Variação entre unidades amostrais;
- **Efeito longitudinal:** Variação intraunidades amostrais.

ANOVA para medidas repetidas

- **Análise de Variância (ANOVA):** É uma técnica pela qual a variabilidade total de um conjunto de dados é separada em vários componentes;
- Usualmente, cada um desses componentes de variação está associada a uma fonte específica de variação;
- Em qualquer tipo de experimento, é de interesse conhecer a magnitude das contribuições de cada uma dessas fontes para a variação total.

ANOVA para medidas repetidas

- **Objetivo:** Comparar a resposta média em cada tempo;
- Considere o caso simples em que não há efeito de grupos:

$$Y_{ij} = \mu + \alpha_i + \tau_j + \varepsilon_{ij},$$

em que $\varepsilon_{ij} \sim N(0, \sigma^2)$, $i = 1, \dots, n$, $j = 1, \dots, m$.

ANOVA para medidas repetidas

Neste nosso caso:

- Os blocos são os indivíduos;
- α_i : o efeito do i -ésimo bloco (indivíduo, unidade amostral);
- α_i : pode ser tratado como efeito fixo ou aleatório. Neste último caso, $\alpha_i \sim N(0, \sigma_\alpha^2)$;
- Os tratamentos são os próprios tempos;
- τ_j : O efeito do j -ésimo tratamento (tempo).

ANOVA para medidas repetidas

$$SQ_{Total} = \sum_{i=1}^n \sum_{j=1}^m (y_{ij} - \bar{y})^2 \quad \bar{y} = \sum_{i=1}^n \sum_{j=1}^m \frac{y_{ij}}{nm}$$

$$SQ_{Tratamento} = n \sum_{j=1}^m (\bar{y}_j - \bar{y})^2 \quad \bar{y}_j = \sum_{i=1}^n \frac{y_{ij}}{n}$$

$$SQ_{Bloco} = m \sum_{i=1}^n (\bar{y}_i - \bar{y})^2 \quad \bar{y}_i = \sum_{j=1}^m \frac{y_{ij}}{m}$$

Sob $H_0 : \tau_1 = \dots = \tau_m$,

$$F = \frac{QM_{Trat}}{QM_{Res}} \sim F_{(m-1), (n-1)(m-1)}$$

Observação

- Podemos utilizar a ANOVA para testar a igualdade de mais de duas médias;
- O teste F vale se $\text{Cov}(\mathbf{Y}_i) = \text{Var}((Y_{i1}, \dots, Y_{im})^T) = \mathbf{\Sigma}$, em que

$$\mathbf{\Sigma} = \sigma^2 \begin{bmatrix} 1 & \rho & \dots & \rho \\ \rho & 1 & \dots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \dots & 1 \end{bmatrix}$$

$$\text{e } \rho = \frac{\text{Cov}(y_{ij}, y_{ij'})}{\sigma^2}.$$

Observação

- O Teste de Friedman (teste não paramétrico) é uma alternativa para a ANOVA, quando a suposição de normalidade, igualdade de variâncias ou esfericidade não for válida.
- O Teste de Friedman usa os postos dos dados ao invés de seus valores observados para obter a estatística de teste.

Limitações da ANOVA

- Não se aplica em situações em que ocorre desbalanceamento;
- Trata o tempo como categórico;
- Usualmente, a correlação tende a diminuir à medida que aumentamos a distância temporal, ou seja, a estrutura esférica não é adequada;
- Difícil de ser utilizado na presença de covariáveis contínuas.
- Variável resposta possuindo distribuição Normal.

Modelos Mistos

Em geral, podemos analisar dados provenientes de estudos com medidas repetidas, por meio de modelos mistos da forma

$$\mathbf{Y}_i = g(\mathbf{X}_i, \mathbf{Z}_i, \boldsymbol{\beta}, \mathbf{b}_i) + \boldsymbol{\varepsilon}_i, \quad i = 1, \dots, n,$$

em que:

- $\mathbf{Y}_i = (y_{i1}, \dots, y_{imi})^T$, com dimensão $m_i \times 1$, é o perfil de respostas da i -ésima unidade experimental.

Modelos Mistos

- β é um vetor de parâmetros (efeitos fixos ou parâmetros de localização) desconhecidos, com dimensão $p \times 1$;
- $X_i = (x_{i1}, \dots, x_{ip})$ é uma matriz de especificação dos efeitos fixos com dimensão $(m_i \times p)$, conhecida e de posto completo, em que $x_{ij} = (x_{ij1}, \dots, x_{ijm_i})^T$ representa o vetor com os m_i valores da j -ésima variável independente, $j = 1, \dots, p$, para a i -ésima unidade amostral.

Modelos Mistos

- \mathbf{b}_i é um vetor, com dimensão $q \times 1$, de variáveis latentes, comumente denominadas efeitos aleatórios, que refletem o comportamento individual da i -ésima unidade amostral;
- \mathbf{Z}_i é uma matriz de especificação dos efeitos aleatórios, com dimensão $m_i \times q$, conhecida e de posto completo;
- g é uma função com derivadas contínuas até à segunda ordem;
- ε_i é um vetor de erros aleatórios com dimensão $m_i \times 1$.

Modelos Mistos

- Em muitos casos, é razoável supor que $\mathbf{b}_i \sim N_q(\mathbf{0}, \mathbf{G})$ e $\varepsilon_i \sim N_{m_i}(\mathbf{0}, \mathbf{R}_i)$, em que \mathbf{G} , com dimensão $q \times q$, e \mathbf{R}_i , com dimensão $m_i \times m_i$, são matrizes simétricas definidas positivas e, além disso, que \mathbf{b}_i e ε_i são variáveis aleatórias independentes;
- Quando g é uma função linear dos efeitos fixos $\boldsymbol{\beta}$ e dos efeitos aleatórios \mathbf{b}_i , o modelo definido anteriormente se reduz ao modelo linear misto

$$Y_i = \mathbf{X}_i \boldsymbol{\beta} + \mathbf{Z}_i \mathbf{b}_i + \varepsilon_i, \quad i = 1, \dots, n.$$

Modelos Mistos

Sob esse modelo, o vetor de respostas associado à i -ésima unidade amostral tem distribuição normal multivariada com vetor de médias e matriz de covariâncias dados, respectivamente, por

$$E(\mathbf{Y}_i) = \mathbf{X}_i \boldsymbol{\beta}$$

e

$$\text{Var}(\mathbf{Y}_i) = \boldsymbol{\Omega}_i = \mathbf{Z}_i \mathbf{G} \mathbf{Z}_i^T + \mathbf{R}_i.$$

Modelos Mistos

- A primeira componente da decomposição de $\text{Var}(\mathbf{Y}_i)$ modela a dispersão dos perfis individuais de resposta e a segunda componente está relacionada com a dispersão da resposta em torno dos perfis individuais;
- Se eliminarmos os componentes aleatórios \mathbf{b}_i e, conseqüentemente, as matrizes \mathbf{Z}_i do modelo linear misto, obteremos os chamados modelos marginais, nos quais a estrutura de covariância é modelada diretamente por meio das matrizes \mathbf{R}_i .

Modelos Mistos

- O modelo linear misto pode ser interpretado como um modelo linear em dois estágios;
- No primeiro estágio, consideramos fixos os efeitos aleatórios \mathbf{b}_i , de forma que $\mathbf{Y}_i | \mathbf{b}_i \sim N(\mathbf{X}_i \boldsymbol{\beta} + \mathbf{Z}_i \mathbf{b}_i, \mathbf{R}_i)$;
- No segundo estágio, supomos que os vetores \mathbf{b}_i são independentes com distribuição $N_q(\mathbf{0}, \mathbf{G})$ e, conseqüentemente, o modelo para a distribuição marginal de \mathbf{Y}_i é $\mathbf{Y}_i \sim N(\mathbf{X}_i \boldsymbol{\beta}, \mathbf{Z}_i \mathbf{G} \mathbf{Z}_i^T + \mathbf{R}_i)$.

Observação

Quando $\mathbf{R}_i = \sigma^2 \mathbf{I}_{m_i}$, o modelo é chamado de modelo de independência condicional homocedástico, indicando que as m_i observações associadas à i -ésima unidade amostral são condicionalmente independentes dado \mathbf{b}_i .

Estrutura de covariância

- Grande parte do esforço empregado na modelagem de dados com medidas repetidas se concentra na estrutura de covariância;
- Em geral, o modelo para a matriz de covariâncias $\mathbf{\Omega}_i$ deve depender da maneira pela qual as observações foram obtidas e do conhecimento sobre o mecanismo gerador das observações.

Estrutura de covariância

- Diggle (1988) e Diggle et al. (2002) comentam que a matriz de covariâncias deve ser suficientemente flexível para incluir no mínimo três fontes diferentes de variação aleatória:
 - (i) a variação devida a efeitos aleatórios, quando as unidades de investigação formam uma amostra aleatória da população de interesse;
 - (ii) a variação que pode ser explicada por correlação serial, em que se esperam observações próximas mais fortemente correlacionadas que observações mais distantes;
 - (iii) a variação devida a erros de medida.

Estrutura de covariância

- No contexto dos modelos mistos, a covariância entre as observações obtidas em uma mesma unidade amostral poderá ser modelada diretamente por meio da matriz \mathbf{R}_i , que representa a estrutura de covariância das observações intraunidades amostrais ou indiretamente, por meio de uma combinação da matriz \mathbf{G} associada aos efeitos aleatórios \mathbf{b}_i , que representam a variabilidade entre as unidades amostrais com a matriz \mathbf{R}_i ;
- Diggle et al. (2002) apresentam sugestões sobre as diferentes maneiras em que modelos para matrizes \mathbf{G} e \mathbf{R}_i podem incluir três possíveis fontes de variação na estrutura de covariância: aquelas correspondente aos efeitos aleatórios, à correlação serial e aos erros de medida.

Estrutura de covariância

- A seguir apresentamos alguns exemplos de estruturas para a matriz $\mathbf{\Omega}_i$ como para suas componentes \mathbf{R}_i e \mathbf{G} ;
- Para isto, usamos a notação $\mathbf{V}_i = \text{Var}(\mathbf{Y}_i)$ e consideramos, para fins de ilustração, $m_i = 4$.

Estrutura Uniforme

- $\theta = (\sigma^2, \tau)^\top$

$$\mathbf{V}_i(\boldsymbol{\theta}) = \begin{bmatrix} \sigma^2 + \tau & \tau & \tau & \tau \\ \tau & \sigma^2 + \tau & \tau & \tau \\ \tau & \tau & \sigma^2 + \tau & \tau \\ \tau & \tau & \tau & \sigma^2 + \tau \end{bmatrix}$$

Estrutura AR(1)

- $\theta = (\sigma^2, \phi)^\top$

$$\mathbf{V}_i(\boldsymbol{\theta}) = \sigma^2 \begin{bmatrix} 1 & \phi & \phi^2 & \phi^3 \\ \phi & 1 & \phi & \phi^2 \\ \phi^2 & \phi & 1 & \phi \\ \phi^3 & \phi^2 & \phi & 1 \end{bmatrix}$$

Estrutura ARMA(1,1)

- $\theta = (\sigma^2, \gamma, \phi)^\top$

$$\mathbf{V}_i(\boldsymbol{\theta}) = \sigma^2 \begin{bmatrix} 1 & \gamma & \gamma\phi & \gamma\phi^2 \\ \gamma & 1 & \gamma & \gamma\phi \\ \gamma\phi & \gamma & 1 & \gamma \\ \gamma\phi^2 & \gamma\phi & \gamma & 1 \end{bmatrix}$$

Estrutura uniforme heterogênea

- $\theta = (\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2, \rho)^\top$

$$\mathbf{V}_i(\boldsymbol{\theta}) = \begin{bmatrix} \sigma_1^2 & \sigma_1\sigma_2\rho & \sigma_1\sigma_3\rho & \sigma_1\sigma_4\rho \\ \sigma_2\sigma_1\rho & \sigma_2^2 & \sigma_2\sigma_3\rho & \sigma_2\sigma_4\rho \\ \sigma_3\sigma_1\rho & \sigma_3\sigma_2\rho & \sigma_3^2 & \sigma_3\sigma_4\rho \\ \sigma_4\sigma_1\rho & \sigma_4\sigma_2\rho & \sigma_4\sigma_3\rho & \sigma_4^2 \end{bmatrix}$$

Não Estruturada

- $\theta = (\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2, \sigma_{12}, \sigma_{13}, \sigma_{14}, \sigma_{23}, \sigma_{24}, \sigma_{34})^\top$

$$\mathbf{V}_i(\boldsymbol{\theta}) = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \sigma_{13} & \sigma_{14} \\ \sigma_{12} & \sigma_2^2 & \sigma_{23} & \sigma_{24} \\ \sigma_{13} & \sigma_{23} & \sigma_3^2 & \sigma_{34} \\ \sigma_{14} & \sigma_{24} & \sigma_{34} & \sigma_4^2 \end{bmatrix}$$

Observações

- Um modelo para a estrutura de covariância deve ser escolhido com base no modelo para a média;
- Utilizar os resíduos para remover o efeito de covariáveis;
- Uma forma alternativa é utilizar variável resposta padronizada por tempo, que somente é válido para estudos balanceados;
- A matriz de correlação empírica para os resíduos indica uma possível estrutura de covariância.

Observações

- **IMPORTANTE:** Existe uma interdependência entre a resposta média e a estrutura de covariância;
- Variâncias e covariâncias são inflacionadas quando a estrutura para a média é incorretamente especificada;
- A covariância entre pares de resíduos depende do modelo para a média;
- O modelo para a covariância deve, então, ser escolhido com base no modelo para a média;
- A decisão deve ser feita com base nos resíduos.

Observações

- Para modelar a estrutura de covariância, pode-se utilizar o modelo "maximal" para a média e testar diferentes estruturas para a covariância;
- Existem algumas estruturas disponíveis para desenhos balanceados com poucos tempos de observação.

Exemplo 1: Níveis de chumbo no sangue

- Tratamento de crianças expostas ao chumbo;
- Estudo clínico aleatorizado para placebo e um tratamento em criança com níveis de chumbo no sangue entre 20-44 microgramas/dL;
- Quatro medidas repetidas de níveis de chumbo na linha de base semana 0, semana 1, semana 4 e semana 6 (desenho balanceado mas não igualmente espaçado);
- 100 crianças aleatoriamente alocadas entre tratamento e placebo.

Tabela 1: Estatísticas descritivas do nível de chumbo, por semana.

| Semana | Mínimo | 1º Quartil | Mediana | Média | 3º Quartil | Máximo |
|--------|--------|------------|---------|-------|------------|--------|
| 0 | 19.70 | 22.05 | 25.60 | 26.41 | 29.60 | 41.10 |
| 1 | 2.80 | 12.38 | 20.60 | 19.09 | 25.02 | 40.80 |
| 4 | 3.00 | 15.25 | 19.70 | 19.79 | 24.60 | 40.40 |
| 6 | 4.10 | 18.25 | 21.25 | 22.20 | 25.60 | 63.90 |

Figura 1: Gráfico Box Plot do nível de chumbo, por semana.




Tabela 2: Estatísticas descritivas do nível de chumbo, por grupo.

| Grupo | Mínimo | 1º Quartil | Mediana | Média | 3º Quartil | Máximo |
|-------|--------|------------|---------|-------|------------|--------|
| A | 2.8 | 12.38 | 19.15 | 19.08 | 24.6 | 63.9 |
| P | 13.5 | 20.67 | 23.90 | 24.66 | 27.9 | 43.3 |

Figura 2: Gráfico Box Plot do nível de chumbo, por grupo.




Tabela 3: Estatísticas descritivas do nível de chumbo, por grupo e semana.

| | Semana | Min | 1º Quartil | Mediana | Média | 3º Quartil | Max |
|---------|--------|------|------------|---------|-------|------------|------|
| Grupo A | 0 | 19.7 | 22.13 | 26.20 | 26.54 | 29.55 | 41.1 |
| | 1 | 2.8 | 7.23 | 12.25 | 13.52 | 17.50 | 39.0 |
| | 4 | 3.0 | 9.13 | 15.35 | 15.51 | 19.73 | 40.4 |
| | 6 | 4.1 | 15.40 | 18.85 | 20.76 | 23.75 | 63.9 |
| Grupo P | 0 | 19.7 | 21.88 | 25.25 | 26.27 | 29.73 | 38.1 |
| | 1 | 14.9 | 20.92 | 24.10 | 24.66 | 27.82 | 40.8 |
| | 4 | 15.3 | 19.83 | 22.45 | 24.07 | 27.45 | 38.6 |
| | 6 | 13.5 | 19.95 | 22.35 | 23.65 | 27.50 | 43.3 |

Figura 3: Gráfico de perfis.





Figura 4: Gráfico de perfis médios.



Exemplo 1: Níveis de chumbo no sangue

- Observa-se que, para o grupo de crianças que tomaram placebo, os níveis de chumbo praticamente permanecem inalterados ao longo do estudo;
- Já para o grupo de crianças submetidas ao agente, os níveis de chumbo se reduzem bastante da semana 0 para a semana 1, e a partir daí têm um ligeiro aumento até a semana 4 e a semana 6;
- Excetuando-se os níveis obtidos na *baseline* (semana 0), que foram praticamente idênticos para ambos os grupos, os níveis de chumbo do grupo tratamento são inferiores aos níveis do grupo placebo.

Tabela 4: Matriz de correlações entre os níveis de chumbo por tempo, usando os dados brutos.

| | <code>dados.Week0</code> | <code>dados.Week1</code> | <code>dados.Week4</code> | <code>dados.Week6</code> |
|--------------------------|--------------------------|--------------------------|--------------------------|--------------------------|
| <code>dados.Week0</code> | 1.000 | 0.419 | 0.468 | 0.562 |
| <code>dados.Week1</code> | 0.419 | 1.000 | 0.845 | 0.557 |
| <code>dados.Week4</code> | 0.468 | 0.845 | 1.000 | 0.583 |
| <code>dados.Week6</code> | 0.562 | 0.557 | 0.583 | 1.000 |

Observação: Usualmente não é adequado obter as correlações utilizando os dados brutos.

Tabela 5: Matriz de correlações entre os níveis de chumbo padronizados por tempo.

| | Week0 | Week1 | Week4 | Week6 |
|-------|-------|-------|-------|-------|
| Week0 | 1.00 | | | |
| Week1 | 0.62 | 1.00 | | |
| Week4 | 0.61 | 0.80 | 1.00 | |
| Week6 | 0.63 | 0.63 | 0.66 | 1.00 |

Figura 5: Gráficos de dispersão dos níveis de chumbo padronizados por tempo.




Tabela 6: Matriz de correlações entre os níveis de chumbo padronizados por tempo, para o grupo placebo.

| | Week0 | Week1 | Week4 | Week6 |
|-------|-------|-------|-------|-------|
| Week0 | 1.00 | | | |
| Week1 | 0.83 | 1.00 | | |
| Week4 | 0.84 | 0.86 | 1.00 | |
| Week6 | 0.76 | 0.76 | 0.87 | 1.00 |

Tabela 7: Matriz de correlações entre os níveis de chumbo padronizados por tempo, para o grupo tratamento.

| | Week0 | Week1 | Week4 | Week6 |
|-------|-------|-------|-------|-------|
| Week0 | 1.00 | | | |
| Week1 | 0.40 | 1.00 | | |
| Week4 | 0.38 | 0.73 | 1.00 | |
| Week6 | 0.50 | 0.50 | 0.45 | 1.00 |

Exemplo 1: Níveis de chumbo no sangue

- Utilizando o modelo com todos os termos (tempo + grupo + interação) e ajuste de Mínimos Quadrados Ordinários.

Tabela 8: Matriz de correlações para os resíduos.

| | Week0 | Week1 | Week4 | Week6 |
|-------|-------|-------|-------|-------|
| Week0 | 1.00 | | | |
| Week1 | 0.57 | 1.00 | | |
| Week4 | 0.57 | 0.78 | 1.00 | |
| Week6 | 0.58 | 0.58 | 0.58 | 1.00 |

Exemplo 1: Níveis de chumbo no sangue

- Utilizando o modelo com todos os termos (tempo + grupo + interação) e ajuste de Mínimos Quadrados Ordinários.

Tabela 8: Matriz de covariâncias para os resíduos.

| | Week0 | Week1 | Week4 | Week6 |
|-------|-------|-------|-------|-------|
| Week0 | 25 | | | |
| Week1 | 19 | 44 | | |
| Week4 | 20 | 35 | 47 | |
| Week6 | 22 | 29 | 30 | 58 |

Exemplo 1: Níveis de chumbo no sangue

- Ajustou-se o modelo "maximal" que consiste nos seguintes termos: (1) intercepto; (2) todos efeitos principais (1 + 3 parâmetros) e (3) interação tempo e grupo (3 parâmetros);
- Iniciou-se com a forma não estruturada de covariância e testou-se possíveis formas estruturadas de covariância.

Exemplo 1: Níveis de chumbo no sangue

- O modelo final com estrutura de variância heterocedástica e não estruturada pareceu ser o mais indicado para a análise destes dados;
- O gráfico de resíduos versus ajustados pode ser útil para validarmos o modelo ajustado.

Tabela 9: Estimativas dos coeficientes do modelo.

| Coefficients: | Value | Std.Error | t-value | p-value |
|-----------------------------------|---------|-----------|-----------|---------|
| (Intercept) | 26.272 | 0.7102939 | 36.98751 | 0.0000 |
| factor (tempo) 1 | -1.612 | 0.7919197 | -2.03556 | 0.0425 |
| factor (tempo) 4 | -2.202 | 0.8149099 | -2.70214 | 0.0072 |
| factor (tempo) 6 | -2.626 | 0.8885239 | -2.95546 | 0.0033 |
| factor (Grupo) A | 0.268 | 1.0045072 | 0.26680 | 0.7898 |
| factor (tempo) 1:factor (Grupo) A | -11.406 | 1.1199436 | -10.18444 | 0.0000 |
| factor (tempo) 4:factor (Grupo) A | -8.824 | 1.1524566 | -7.65669 | 0.0000 |
| factor (tempo) 6:factor (Grupo) A | -3.152 | 1.2565625 | -2.50843 | 0.0125 |

Observações

- Os termos de ordem inferior devem sempre aparecer no modelo na presença daqueles de ordem superior, ou seja, ao incluirmos a interação entre grupo e tempo, os efeitos principais de grupo e tempo devem aparecer na estrutura de regressão;
- Uma exceção pode ser aberta, ao assumirmos, em estudos experimentais, igualdade de média na linha de base. Desta forma, excluimos o efeito principal de grupo;
- A vantagem deste ajuste é a parcimônia, ao reduzirmos um parâmetro do modelo

Tabela 10: Estimativas dos coeficientes do modelo supondo igualdade de médias na linha de base.

Coefficients:

| | Value | Std.Error | t-value | p-value |
|-----------------------------------|------------|-----------|-----------|---------|
| (Intercept) | 26.406000 | 0.4998905 | 52.82357 | 0.0000 |
| factor (tempo) 1 | -1.644501 | 0.7824043 | -2.10186 | 0.0362 |
| factor (tempo) 4 | -2.231356 | 0.8073816 | -2.76369 | 0.0060 |
| factor (tempo) 6 | -2.642065 | 0.8864611 | -2.98046 | 0.0031 |
| factor (tempo) 1:factor (Grpo) A | -11.340999 | 1.0931205 | -10.37488 | 0.0000 |
| factor (tempo) 4:factor (Grpo) A | -8.765289 | 1.1312579 | -7.74827 | 0.0000 |
| factor (tempo) 6:factor (Grupo) A | -3.119870 | 1.2507769 | -2.49435 | 0.0130 |

- Tempo = 0 (linha de base): $E(Y_{ij}|\text{Grupo} = P) = E(Y_{ij}|\text{Grupo} = A) = \beta_1$
Estimativa: $26,4 \pm 1,96 * 0.5$ (25,5; 27,3)
- Tempo = 1: $E(Y_{ij}|\text{Grupo} = A) = E(Y_{ij}|\text{Grupo} = P) = (\beta_1 + \beta_2 + \beta_5) - (\beta_1 + \beta_2) = \beta_5$
Estimativa: $= -11,3 \pm 1,96 * 1.09$ (-13,5; -9,1)
- Houve uma redução da resposta do tempo =1 para o 6 no grupo =P (efeito placebo)?
Grupo = P: $E(Y_{ij}|\text{Tempo} = 1) = E(Y_{ij}|\text{Tempo} = 6) = \beta_2 - \beta_4$. Estimativa:
 $-1,64 + 2.64 = 1.0$ e a $\widehat{Var}(\hat{\beta}_2 - \hat{\beta}_4) = \widehat{Var}(\hat{\beta}_2) + \widehat{Var}(\hat{\beta}_4) - 2\widehat{Cov}(\hat{\beta}_2, \hat{\beta}_4) = 0.6^2$,
IC (-0,17; 2,17), não existe evidência de efeito placebo.

Especialização em *Data Science* e Estatística Aplicada

Módulo IV – Análise de Dados Longitudinais

Prof. Dr. Márcio Luis Lanfredi Viola
lanfredi@ufscar.br