

# Especialização em *Data Science* e Estatística Aplicada

## Módulo IV - Análise de Séries Temporais

Prof. Dr. Eder Angelo Milani

Goiânia, 2025



# Conteúdo Programático

- Principais conceitos de séries temporais. (Aula 1)
- Funções de autocovariância e de autocorrelação. (Aula 1)
- Definição e estimação da tendência e da sazonalidade. (Aulas 2 e 3)
- Métodos de suavização. (Aulas 3 e 4)
- Modelagem Box-Jenkins: modelos AR, MA, ARMA, ARIMA e SARIMA.
- Análise de séries temporais interrompidas.



# Conteúdo - Aula 5

## 1. Modelagem Box-Jenkins: ARIMA e SARIMA

- Introdução
- ARIMA
- SARIMA
  - Sazonalidade determinística
  - Sazonalidade estocástica



# Introdução

Os modelos estudados até o momento são apropriados para descrever séries estacionárias, isto é, séries que se desenvolvem no tempo ao redor de uma média constante. Muitas séries encontradas na prática não são estacionárias.

**O que fazer quando a série apresentar tendência?**

# Introdução

Voltando a Aula 1 ...

**Obs.: um procedimento que é também utilizado para eliminar a tendência de um série é aquele de tomar diferenças, como foi definido anteriormente.**

Mas o que é essa tal de diferença?

A primeira diferença de  $Z_t$  é definida por

$$\Delta Z_t = Z_t - Z_{t-1},$$

a segunda diferença é

$$\Delta^2 Z_t = \Delta[\Delta Z_t] = \Delta[Z_t - Z_{t-1}] = Z_t - 2Z_{t-1} + Z_{t-2}.$$

# Modelo autorregressivo integrado de médias móveis

Se  $W_t = \Delta Z_t$  for estacionária, podemos representar  $W_t$  por um modelo ARMA( $p, q$ ), ou seja,

$$\phi(B)W_t = \theta(B)a_t. \quad (1)$$

Se  $W_t$  for uma diferença de  $Z_t$ , então  $Z_t$  é uma *integral* de  $W_t$ , daí dizemos que  $Z_t$  segue um modelo autorregressivo, *integrado*, de médias móveis, ou modelo ARIMA,

$$\phi(B)\Delta^d Z_t = \theta(B)a_t, \quad (2)$$

de ordem  $(p, d, q)$  e escrevemos ARIMA( $p, d, q$ ), se  $p$  e  $q$  são as ordens de  $\phi(B)$  e  $\theta(B)$ , respectivamente.

# Modelo autorregressivo integrado de médias móveis

O modelo (2) supõe que a  $d$ -ésima diferença da série  $Z_t$  pode ser representada por um modelo ARMA, estacionário e invertível. Na maioria dos casos usuais,  $d = 1$  ou  $d = 2$ , que corresponde a dois casos interessantes e comuns de não-estacionariedade homogênea:

- (a) séries não-estacionárias quanto ao nível: oscilam ao redor de um nível médio durante algum tempo e depois saltam para outro nível temporário. Para torná-las estacionárias é suficiente tomar uma diferença; este é o caso típico de séries econômicas;
- (b) séries não-estacionárias quanto à inclinação: oscilam numa direção por algum tempo e depois mudam para outra direção temporariamente. Para torná-las estacionárias é necessário tomar a segunda diferença.

# Modelo autorregressivo integrado de médias móveis

**Exemplo:** Alguns casos particulares do modelo (2) são:

- (i) ARIMA(0,1,1):  $\Delta Z_t = (1 - \theta B)a_t$ ;
- (ii) ARIMA(1,1,1):  $(1 - \phi B)\Delta Z_t = (1 - \theta B)a_t$ ;
- (iii) ARIMA(p,0,0) = AR(p)
- (iv) ARIMA(0,0,q) = MA(q)
- (v) ARIMA(p,0,q) = ARMA(p, q)

O modelo ARIMA(1,1,1) também pode ser escrito como

$$\begin{aligned}(1 - \phi B)\Delta Z_t &= (1 - \theta B)a_t \\ (1 - \phi B)(1 - B)Z_t &= (1 - \theta B)a_t,\end{aligned}$$

ou ainda por:  $Z_t = (1 + \phi)Z_{t-1} - \phi Z_{t-2} + a_t - \theta a_{t-1}$ .

# Teste para raiz unitária

O teste Dickey-Fuller aumentado (do inglês *augmented Dickey-Fuller*) - ADF - é provavelmente o teste de hipóteses para raízes unitárias mais utilizado. A grosso modo, se tomarmos um processo da forma  $Z_t = \theta_0 + \phi Z_{t-1} + a_t$ , o objetivo do teste é, então, inferir se  $\phi = 1$ .

O problema é que estimar o modelo sob a hipótese de não estacionariedade nos faz incorrer no problema de regressão espúria (duas variáveis apresentam uma correlação forte e significativa, mas essa relação é falsa e não existe uma causa e efeito real entre elas).

# Teste para raiz unitária

Dickey e Fuller (1979) propõem realizar o teste sob a série diferenciada e, três configurações que possibilitam obter as estatísticas de testes adequadas. Ainda que a série seja diferenciada, **sob a hipótese nula de existência de raiz unitária**, é possível que os resíduos das regressões estejam correlacionados. Para contornar esse problema, adicionam-se termos defasados da variável dependente, sendo que para determinar a quantidade geralmente se usam critérios de informação do tipo AIC e BIC.

As equações do teste são:

$$\Delta Z_t = \gamma Z_{t-1} + \sum_{t=1}^p \beta_i \Delta Z_{t-1} + a_t,$$

$$\Delta Z_t = \theta_0 + \gamma Z_{t-1} + \sum_{t=1}^p \beta_i \Delta Z_{t-1} + a_t,$$

$$\Delta Z_t = \theta_0 + \beta t + \gamma Z_{t-1} + \sum_{t=1}^p \beta_i \Delta Z_{t-1} + a_t.$$

# Aplicação

**Aplicação no software R.**

# SARIMA

Anteriormente, estudamos o problema da sazonalidade e os procedimentos de estimação e eliminação da componente sazonal determinística de uma série sazonal.

É possível que, mesmo após eliminar a componente sazonal determinística, ainda reste autocorrelação significativa em:

- (i) “lags” de baixa ordem, indicando que os resíduos ainda são correlacionados, podendo-se ajustá-los através de um modelo ARIMA, por exemplo;
- (ii) “lags” sazonais, isto é, múltiplos de período  $s$ . Isto significa que há necessidade de se considerar uma sazonalidade estocástica, ou seja, ajustar à série original um modelo **ARIMA sazonal (SARIMA)**.

# Sazonalidade determinística

Consideremos, por simplicidade de exposição, dados observados mensalmente e sazonalidade de período  $s = 12$ . Tratemos, separadamente, os dois tipos de sazonabilidade.

Quando  $\{Z_t\}$  exibe um comportamento sazonal determinístico com período 12, um modelo que pode ser útil é:

$$Z_t = \mu_t + N_t,$$

onde  $\mu_t$  é uma função determinística periódica, satisfazendo  $\mu_t - \mu_{t-12} = 0$  e  $N_t$  é um processo estacionário que pode ser modelado por um ARMA( $p, q$ ).

# Sazonalidade determinística

Dessa maneira,  $N_t$  satisfaz a equação

$$\phi(B)N_t = \theta(B)a_t,$$

onde  $a_t$  é ruído branco e  $\mu_t$  é modelado utilizando variáveis “dummies” ou com pares de funções seno e cosseno, como já vimos anteriormente.

# Sazonalidade determinística

## Identificação

A identificação do modelos  $Z_t = \mu_t + N_t$ , é feita em dois passos:

1. Obtemos estimativas dos parâmetros que são utilizados para estimar a sazonalidade por meio de uma análise de regressão.
2. Calculamos os resíduos:

$$\hat{N}_t = Z_t - \hat{\mu}_t,$$

e examinamos as funções de autocorrelação e autocorrelação parcial para identificar um modelo ARMA( $p, q$ ) para  $N_t$ .

# Sazonalidade determinística

## Estimação

O processo de estimação é feito em partes, seguindo o roteiro:

- estimação de  $\mu_t$ , sendo modelado por variáveis “dummies” ou com pares de funções seno e cosseno;
- obtenção de  $\hat{N}_t = Z_t - \hat{S}_t$ , e na sequência estimação do modelo ARMA( $p, q$ ) para  $N_t$ ;
- por fim, estimação conjunta de  $\mu_t$  e do modelo ARMA( $p, q$ ).

# Aplicação

**Aplicação no software R.**

# SARIMA

Do mesmo modo que podemos modelar uma série  $Z_t$ , observada mês a mês, por um modelo ARIMA, por exemplo:

$$Z_t = \phi Z_{t-1} + a_t,$$

poderíamos modelar uma associação ano a ano na série  $Z_t$  através de um modelo ARIMA sazonal, sendo dado por:

$$Z_t = \Phi Z_{t-12} + a_t.$$

De maneira similar, podemos considerar um modelo de médias móveis sazonais, como:

$$Z_t = a_t - \Theta a_{t-12}.$$

# SARIMA

Portanto, a ideia é relacionar uma observação  $Z_t$ , correspondente a um determinado mês, janeiro por exemplo, com observações correspondentes a janeiros anteriores, através de um modelo ARIMA sazonal da forma:

$$\Phi(B^{12})\Delta_{12}^D Z_t = \Theta(B^{12})\alpha_t,$$

sendo que

- $\Phi(B^{12}) = 1 - \Phi_1 B^{12} - \dots - \Phi_P B^{12P}$ , é o operador autorregressivo sazonal de ordem  $P$ , estacionário;
- $\Theta(B^{12}) = 1 - \Theta_1 B^{12} - \dots - \Theta_Q B^{12Q}$ , é o operador de médias móveis sazonal de ordem  $Q$ , invertível;
- $\Delta_{12} = (1 - B^{12})$ , é o operador diferença sazonal,
- $\Delta_{12}^D = (1 - B^{12})^D$ , indicando o número de “diferenças sazonais”.

# SARIMA

Uma diferença como o modelo ARIMA usual é que os  $\alpha_t, \alpha_{t-1}, \dots$ , não seriam ruído branco. Sem perda de generalidade, o valor observado de janeiro de um determinado ano, além de ser relacionada com janeiros anteriores, será também relacionada com dezembro, novembro do ano anterior, implicando que  $\alpha_t, \alpha_{t-1}$ , etc., sejam relacionados.

Para descrever esta relação introduzimos, para os  $\alpha_t$ , o modelo ARIMA usual, dado por

$$\phi(B)\Delta^d\alpha_t = \theta(B)a_t,$$

sendo que agora  $a_t$  é ruído branco e

- $\phi(B) = 1 - \phi_1B - \dots - \phi_pB^p$ , é o operador autorregressivo de ordem  $p$ , estacionário;
- $\theta(B) = 1 - \theta_1B - \dots - \theta_qB^q$ , é o operador de médias móveis de ordem  $q$ , invertível;
- $\Delta^d = (1 - B)^d$ , indica o número de diferenças.

# SARIMA

Fazendo a junção das equações

$$\begin{aligned}\Phi(B^{12})\Delta_{12}^D Z_t &= \Theta(B^{12})\alpha_t, \\ \phi(B)\Delta^d \alpha_t &= \theta(B)a_t,\end{aligned}$$

obtemos

$$\phi(B)\Phi(B^{12})\Delta^d \Delta_{12}^D Z_t = \theta(B)\Theta(B^{12})a_t,$$

que é chamado de modelo **ARIMA sazonal multiplicativo** ou simplesmente de **SARIMA**, de ordem  $(p, d, q) \times (P, D, Q)_{12}$ .

O modelo SARIMA implica que devemos realizar  $d$  diferenças simples e  $D$  diferenças sazonais da série  $Z_t$ , de modo que o processo  $W_t = \Delta^d \Delta_{12}^D Z_t$  seja estacionário.

# SARIMA

**Exemplo:** Um modelo de médias móveis puro,  $\text{SARIMA}(0, 0, 0) \times (0, 0, Q)_{12} = \text{SMA}(Q)$ , é da forma

$$Z_t = a_t - \Theta_1 a_{t-12} - \cdots - \Theta_Q a_{t-12Q}.$$

# SARIMA

**Exemplo:** Um modelo de médias móveis puro,  $\text{SARIMA}(0, 0, 0) \times (0, 0, Q)_{12} = \text{SMA}(Q)$ , é da forma

$$Z_t = a_t - \Theta_1 a_{t-12} - \cdots - \Theta_Q a_{t-12Q}.$$

**Exemplo:** Um modelo autorregressivo sazonal puro,  $\text{SARIMA}(0, 0, 0) \times (P, 0, 0)_{12} = \text{SAR}(P)$ , é da forma

$$Z_t = \Phi_1 Z_{t-12} + \cdots + \Phi_P Z_{t-12P} + a_t.$$

# SARIMA

**Exemplo:** Um modelo SARIMA(1, 0, 1)  $\times$  (1, 0, 1)<sub>12</sub> tem a forma

$$(1 - \phi B)(1 - \Phi B^{12})Z_t = (1 - \theta B)(1 - \Theta B^{12})a_t,$$

ou

$$Z_t = \phi Z_{t-1} + \Phi Z_{t-12} - \phi\Phi Z_{t-13} + a_t - \theta a_{t-1} - \Theta a_{t-12} + \theta\Theta a_{t-13}.$$

# Aplicação

**Aplicação no software R.**

# Especialização em *Data Science* e Estatística Aplicada

## Módulo IV - Análise de Séries Temporais

Prof. Dr. Eder Angelo Milani

[edermilani@ufg.br](mailto:edermilani@ufg.br)

