

# Especialização em *Data Science* e Estatística Aplicada

## Módulo IV - Análise de Séries Temporais

Prof. Dr. Eder Angelo Milani

Goiânia, 2025

**IME**

INSTITUTO DE  
MATEMÁTICA E  
ESTATÍSTICA

**FEN**

FACULDADE DE  
ENFERMAGEM



**UFG**

UNIVERSIDADE  
FEDERAL DE GOIÁS



# Conteúdo Programático

- Principais conceitos de séries temporais. (Aula 1)
- Funções de autocovariância e de autocorrelação. (Aula 1)
- Definição e estimação da tendência e da sazonalidade. (Aulas 2 e 3)
- Métodos de suavização. (Aula 3)
- Modelagem Box-Jenkins: modelos AR, MA, ARMA, ARIMA e SARIMA.
- Análise de séries temporais interrompidas.

# Conteúdo - Aula 4

## 1. Modelagem Box-Jenkins: modelos AR, MA e ARMA

- Introdução
- Modelos autorregressivos
- Modelos de médias móveis
- Modelos autorregressivos e de médias móveis
- Função de autocorrelação parcial
- Identificação de modelos ARMA
- Diagnóstico de modelos ARMA
  - Teste de Box-Pierce

# Introdução

Uma metodologia bastante utilizada na análise de modelos paramétricos é conhecida como abordagem de Box e Jenkins (1970). Tal metodologia consiste em ajustar modelos autorregressivos integrados de médias móveis, **ARIMA(p, d, q)**, a um conjunto de dados. Para uma atualização recente do texto original veja Box *et al.* (2016).

# Introdução

A estratégia para a construção do modelo será baseada em um ciclo iterativo, no qual a escolha da estrutura do modelo é baseada nos próprios dados. Os estágios do ciclo iterativo são:

- (a) uma classe geral de modelos é considerada para a análise (*especificação*);
- (b) há *identificação* de um modelo, com base na análise de autocorrelações, autocorrelações parciais e outros critérios;
- (c) a seguir vem a fase de *estimação*, na qual os parâmetros do modelo identificado são estimados;
- (d) finalmente, há a *verificação* ou *diagnóstico* do modelo ajustado, através de uma análise de resíduos, para se saber se este é adequado para os fins em vista (previsão, por exemplo).

# Introdução

Caso o modelo não seja adequado, o ciclo é repetido, voltando-se à fase de identificação.

Um procedimento que muitas vezes é utilizado é identificar não só um único modelo, mas alguns modelos que serão então estimados e verificados. Se o propósito é previsão, escolher-se-á entre os modelos ajustados o melhor, por exemplo, no sentido de fornecer o menor erro quadrático médio de previsão.

A fase crítica do procedimento acima é a identificação. É possível que vários pesquisadores identifiquem modelos diferentes para a mesma série temporal.

# Introdução

Em geral, os modelos postulados são *parcimoniosos*, pois contêm um número pequeno de parâmetros e as previsões obtidas são bastante precisas, comparando-se favoravelmente com os demais métodos de previsão.

Uma desvantagem da técnica de Box e Jenkins é que a sua utilização requer experiência e algum conhecimento além do uso automático de um pacote de computador.

# Introdução

Vamos introduzir uma notação de operadores que será usada extensivamente neste e nos capítulos seguintes. A familiaridade com esta notação facilitará bastante a manipulação dos modelos a serem estudados.

Estes operadores são:

- (a) operador translação para o passado, denotado por  $B$  e definido por

$$BZ_t = Z_{t-1}, \quad B^m Z_t = Z_{t-m};$$

- (b) operador diferença, já definido antes,

$$\Delta Z_t = Z_t - Z_{t-1} = (1 - B)Z_t.$$

Segue-se que  $\Delta = 1 - B$ .




# Introdução

**Definição:** Um processo estocástico  $Z = \{Z(t), t \in T\}$  diz-se fracamente estacionário ou estacionário de segunda ordem se e somente se

- (i)  $E(Z(t)) = \mu(t) = \mu$ , constante, para todo  $t \in T$ ;
- (ii)  $E(Z^2(t)) < \infty$ , para todo  $t \in T$ ;
- (iii)  $\gamma(t_1, t_2) = Cov(Z(t_1), Z(t_2))$  é uma função de  $|t_1 - t_2|$ .

# Introdução

Os modelos que serão estudados agora são casos particulares de um *modelo de filtro linear*. Este modelo supõe que a série temporal seja gerada através de um filtro linear (ou sistema linear), cuja entrada é um ruído branco, ver Figura 1



**Figura 1:** Filtro linear, com entrada  $a_t$ , saída  $Z_t$  e função de transferência  $\Psi(B)$  - Figura retirada de Morettin e Toloi (2006)

# Introdução

Formalmente, temos que

$$Z_t = \mu + a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \dots = \mu + \psi(B)a_t, \quad (1)$$

em que

$$\psi(B) = 1 + \psi_1 B + \psi_2 B^2 + \dots$$

é denominada função de transferência do filtro e  $\mu$  é um parâmetro determinando o nível da série.

$Z_t$  dado pela equação (1) é um processo linear (discreto). Lembremos que

$$\begin{aligned} E(a_t) &= 0, \forall t, \\ \text{Var}(a_t) &= \sigma_a^2, \forall t, \\ E(a_t a_s) &= 0, s \neq t. \end{aligned}$$

# Introdução

Chamando  $\tilde{Z}_t = Z_t - \mu$ , temos que

$$\tilde{Z}_t = \psi(B)a_t.$$

Se a sequência de pesos  $\{\psi_j, j \geq 1\}$  for finita ou infinita e convergente, o filtro é estável (somável) e  $Z_t$  é estacionária. Neste caso,  $\mu$  é a média do processo.

Caso contrário,  $Z_t$  é não-estacionária e  $\mu$  não tem significado específico, a não ser como um ponto de referência para o nível da série.

# Introdução

Podemos escrever  $\tilde{Z}_t$  em uma forma alternativa, como uma soma ponderada de valores passados  $\tilde{Z}_{t-1}, \tilde{Z}_{t-2}, \dots$  mais um ruído  $a_t$ , ou seja,

$$\tilde{Z}_t = \pi_1 \tilde{Z}_{t-1} + \pi_2 \tilde{Z}_{t-2} + \dots + a_t = \sum_{j=1}^{\infty} \pi_j \tilde{Z}_{t-j} + a_t.$$

Segue-se que  $\left(1 - \sum_{j=1}^{\infty} \pi_j B^j\right) \tilde{Z}_t = a_t$ , ou

$$\pi(B) \tilde{Z}_t = a_t,$$

onde  $\pi(B)$  é o operador  $\pi(B) = 1 - \pi_1 B - \pi_2 B^2 - \dots$ . Esta forma de escrever é chamada de invertível.

# Modelos autorregressivos

Se em

$$\tilde{Z}_t = \pi_1 \tilde{Z}_{t-1} + \pi_2 \tilde{Z}_{t-2} + \dots + a_t = \sum_{j=1}^{\infty} \pi_j \tilde{Z}_{t-j} + a_t,$$

$\pi_j = 0$ , para  $j > p$ , obtemos um modelo *autorregressivo de ordem  $p$* , que denotaremos  $AR(p)$ , ou seja,

$$\tilde{Z}_t = \phi_1 \tilde{Z}_{t-1} + \phi_2 \tilde{Z}_{t-2} + \dots + \phi_p \tilde{Z}_{t-p} + a_t,$$

renomeando os pesos de  $\pi_j$  para  $\phi_j$ , de acordo com a notação usual. Se definirmos o operador autorregressivo estacionário de ordem  $p$  por

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p,$$

então pode-se escrever  $\phi(B)\tilde{Z}_t = a_t$ .

# Modelos autorregressivos

**Exemplo:** O caso mais simples é o modelo autorregressivo de ordem  $p = 1$ , AR(1), dado por

$$\tilde{Z}_t = \phi \tilde{Z}_{t-1} + a_t,$$

de maneira que  $Z_t$  depende apenas de  $Z_{t-1}$  e do ruído no instante  $t$ .

Como  $\pi(B) = \phi(B) = 1 - \phi B$ , o processo é sempre invertível.

Substituindo-se, sucessivamente,  $\tilde{Z}_{t-1}, \tilde{Z}_{t-2}, \dots$ , etc, obtemos

$$\tilde{Z}_t = a_t + \phi a_{t-1} + \phi^2 a_{t-2} + \phi^3 a_{t-3} + \dots = \sum_{j=0}^{\infty} \phi^j a_{t-j},$$

ou seja,

$$\tilde{Z}_t = \psi(B)a_t = (1 + \phi B + \phi^2 B^2 + \dots)a_t$$

# Modelos autorregressivos

## Estacionariedade e Invertibilidade

Como  $\pi(B) = \phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$  é finito, não há restrições sobre os parâmetros para assegurar a invertibilidade de  $Z_t$ .

Para garantir a estacionariedade, temos a condição de que a equação característica  $\phi(B) = 0$  tenha raízes fora do círculo unitário.



# Modelos autorregressivos

Muitas vezes o modelo pode ser apresentado de maneira diferente, figurando uma constante, que não é a média. Por exemplo, considere o modelo  $AR(1)$  dado por

$$Z_t = \phi Z_{t-1} + a_t + \theta_0, \quad |\phi| < 1. \quad (2)$$

Então, tomando a esperança de ambos os lados,

$$E(Z_t) = \phi E(Z_{t-1}) + E(a_t) + \theta_0.$$

Como o processo é estacionário,  $E(Z_t) = E(Z_{t-1}) = \mu$ , logo  $\mu = \phi\mu + \theta_0$ , e portanto,

$$\mu = \frac{\theta_0}{1 - \phi}.$$

# Modelos autorregressivos

Então, escrevendo-se na forma simplificada

$$\begin{aligned}\tilde{Z}_t &= \phi \tilde{Z}_{t-1} + a_t \\ \tilde{Z}_t &= Z_t - \mu = Z_t - \left( \frac{\theta_0}{1 - \phi} \right).\end{aligned}$$

Observe que, em (2), se  $\theta_0 = 0$ ,  $\mu = 0$ . Em geral, um processo AR(p) pode ser escrito como

$$Z_t - \mu = \phi_1(Z_{t-1} - \mu) + \dots + \phi_p(Z_{t-p} - \mu) + a_t,$$

ou ainda

$$Z_t = \theta_0 + \phi_1 Z_{t-1} + \dots + \phi_p Z_{t-p} + a_t,$$

com

$$\mu = \frac{\theta_0}{1 - \phi_1 - \dots - \phi_p}.$$

# FAC de um modelo AR

A função de autocorrelação de um modelo  $AR(p)$  é dado por

$$\rho_j = \phi_1 \rho_{j-1} + \phi_2 \rho_{j-2} + \dots + \phi_p \rho_{j-p}, \quad j > 0,$$

que também pode ser escrita como

$$\phi(B)\rho_j = 0,$$

onde o operador  $B$  agora age em  $j$  :  $B\rho_j = \rho_{j-1}$ .

# FAC de um modelo AR(1)

Para um modelo AR(1)






Figura 2: A teórica de um modelo AR(1), com  $\phi = 0,8$  em (a) e,  $\phi = -0,8$  em (b) - Figura retirada de Morettin e Tolo (2006)

# FAC de um modelo AR(2)

Para um modelo AR(2)



**Figura 3:** FAC para o modelo AR(2), em (a), com  $\phi_1 = 0,5$  e  $\phi_2 = 0,3$ , em (b), com  $\phi_1 = 1,0$  e  $\phi_2 = -0,89$  - Figura retirada de Morettin e Toloí (2006)

# Modelos autorregressivos

**Exemplo:** Considere, agora, o modelo AR(2)

$$\tilde{Z}_t = \phi_1 \tilde{Z}_{t-1} + \phi_2 \tilde{Z}_{t-2} + a_t,$$

que pode ser escrito na forma  $\phi(B)\tilde{Z}_t = a_t$ , com


$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2.$$

Então, pode-se demonstrar que  $Z_t$  é estacionário se (as raízes de  $\phi(B) = 0$  estiver fora do círculo unitário).

$$\phi_1 + \phi_2 < 1, \quad \phi_2 - \phi_1 < 1, \quad -1 < \phi_2 < 1.$$

# Modelos autorregressivos

Esta região está representada na Figura 4



**Figura 4:** Região de estacionariedade para um modelo AR(2) - Figura retirada de Morettin e Toloi (2006)

# Aplicação

**Aplicação no *software* R.**



# Modelos de médias móveis

Considere o processo linear dado em (1), ou seja,

$$Z_t = \mu + a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \dots = \mu_t + \psi(B)a_t,$$

e suponha que  $\psi_j = 0$ ,  $j > q$ ; obtemos um processo de médias móveis de ordem  $q$ , que denotaremos por  $MA(q)$  (de “moving average”). De agora em diante usaremos a notação

$$Z_t = \mu + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q},$$

e sendo  $\tilde{Z}_t = Z_t - \mu_t$ , teremos

$$\tilde{Z}_t = (1 - \theta_1 B - \dots - \theta_q B^q)a_t = \theta(B)a_t,$$

onde  $\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$  é o operador de médias móveis de ordem  $q$ .

# Modelos de médias móveis

**Exemplo:** O caso mais simples é o MA(1), ou seja,

$$\tilde{Z}_t = a_t - \theta a_{t-1},$$

ou

$$\tilde{Z}_t = (1 - \theta B)a_t,$$

de modo que  $\theta(B) = 1 - \theta B$ .

Como  $\psi(B) = 1 - \theta B$  é finito, o processo é sempre estacionário.

Podemos obter a forma invertível, que é dada por

$$\tilde{Z}_t = -\theta \tilde{Z}_{t-1} - \theta^2 \tilde{Z}_{t-2} - \dots + a_t.$$

# Modelos de médias móveis

## Estacionariedade e Invertibilidade

Dado que  $\psi(B) = 1 - \theta_1 B - \dots - \theta_q B^q$ , não há restrições sobre os parâmetros  $\theta_j$  para que o processo seja estacionário.

Usando um argumento completamente similar ao que foi feito para um modelo  $AR(p)$ , no caso de estacionariedade, pode-se verificar que a condição de invertibilidade para um modelo  $MA(q)$  é que as raízes da equação característica  $\theta(B) = 0$  estejam fora do círculo unitário. Nestas condições, um modelo  $MA(q)$  é equivalente a um modelo  $AR$  de ordem infinita.

# Modelos de médias móveis

## Função de autocorrelação


A FAC do processo do processo  $MA(q)$  é dado por

$$\rho_j = \begin{cases} \frac{-\theta_j + \theta_1\theta_{j+1} + \theta_2\theta_{j+2} + \dots + \theta_{q-j}\theta_q}{1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2}, & j = 1, \dots, q, \\ 0, & j > q. \end{cases}$$

Observemos, então, que a FAC de um processo  $MA(q)$  é igual a zero para "lags" maiores do que  $q$ , ao contrário do que acontece com um processo AR.

# FAC do MA(1)

Para um modelo MA(1)




Digitalizado com CamScanner

**Figura 5:** Fac do modelo MA(1) com  $\theta = 0,8$  - Figura retirada de Morettin e Toloi (2006)

# Modelos de médias móveis

Para um modelo MA(2)



Reproduzido com o EViews

**Figura 6:** Fac do modelo MA(2) com  $\theta_1 = 0,5$  e  $\theta_2 = -0,3$  - Figura retirada de Morettin e Toloi (2006)

# Modelos de médias móveis

**Exemplo:** Consideremos, agora, um modelo MA(2),

$$\tilde{Z}_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}.$$

O processo resultante será estacionário para quaisquer valores de  $\theta_1$  e  $\theta_2$ , mas invertível somente se as raízes de  $\theta(B) = 1 - \theta_1 B - \theta_2 B^2 = 0$  estiverem fora do círculo unitário, obtendo-se

$$\theta_2 + \theta_1 < 1, \quad \theta_2 - \theta_1 < 1, \quad -1 < \theta_2 < 1,$$

que são equivalentes às condições de estacionariedade para um AR(2).

# Aplicação

**Aplicação no *software* R.**



# Modelos autorregressivos e de médias móveis

Os modelos autorregressivos são bastante populares em algumas áreas, como em Economia, onde é natural pensar o valor de alguma variável no instante  $t$  como função de valores defasados da mesma variável.

Para muitas séries encontradas na prática, se quisermos um modelo com um número não muito grande de parâmetros, a inclusão de termos autorregressivos e de médias móveis é a solução adequada.

# Modelos autorregressivos e de médias móveis

Surge, então, os modelos ARMA( $p, q$ ), da forma

$$\tilde{Z}_t = \phi_1 \tilde{Z}_{t-1} + \dots + \phi_p \tilde{Z}_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}. \quad (3)$$

Se  $\phi(B)$  e  $\theta(B)$  são os operadores autorregressivos e de médias móveis, respectivamente, introduzidos anteriormente, podemos escrever (3) na forma compacta

$$\phi(B)\tilde{Z}_t = \theta(B)a_t.$$

# Modelos autorregressivos e de médias móveis

**Exemplo:** Um modelo frequentemente usado é o ARMA(1, 1), onde  $p = q = 1$ ,  $\phi(B) = 1 - \phi B$  e  $\theta(B) = 1 - \theta B$ , ou seja, (3) reduz-se a

$$\tilde{Z}_t = \phi \tilde{Z}_{t-1} + a_t - \theta a_{t-1}. \quad (4)$$

É fácil ver, substituindo-se sequencialmente  $\tilde{Z}_{t-1}, \tilde{Z}_{t-2}, \dots$  em (4), que se obtém  $\tilde{Z}_t$  escrito na forma de um processo linear (ou médias móveis de ordem infinita),

$$\tilde{Z}_t = \psi(B)a_t,$$

onde  $\psi_j = \phi^{j-1}(\phi - \theta)$ ,  $j \geq 1$ , de modo que o processo será estacionário se  $|\phi| < 1$ .

# Modelos autorregressivos e de médias móveis

Do mesmo modo, o modelo ARMA(1, 1) pode ser escrito na forma

$$\pi(B)\tilde{Z}_t = a_t,$$

onde os pesos  $\pi = \theta^{j-1}(\phi - \theta)$ ,  $j \geq 1$ , de modo que o processo é invertível se  $|\theta| < 1$ .

Segue-se que a condição de estacionariedade para um processo ARMA(1, 1) é a mesma que para um processo AR(1) e a condição de invertibilidade é a mesma que para um processo MA(1).

Estas conclusões generalizam-se para um processo ARMA( $p, q$ ) qualquer.

# Modelos autorregressivos e de médias móveis

## Estacionariedade e Invertibilidade

Do que foi exposto acima, podemos concluir que o processo é estacionário se as raízes de  $\phi(B) = 0$  caírem todas fora do círculo unitário e o processo é invertível se todas as raízes de  $\theta(B) = 0$  caírem fora do círculo unitário.

# Modelos autorregressivos e de médias móveis


## Função de autocorrelação

A FAC é

$$\rho_j = \phi_1 \rho_{j-1} + \phi_2 \rho_{j-2} + \cdots + \phi_p \rho_{j-p}, \quad j > q,$$

do que se deduz que as autocorrelações de “lags”  $1, 2, \dots, q$  serão afetadas diretamente pelos parâmetros de médias móveis, mas para  $j > q$  as mesmas comportam-se como nos modelos autorregressivos.

# Modelos autorregressivos e de médias móveis



CC Digitalizado com CamScanner

**Figura 7:** FAC teórica do modelo ARMA(1,1), com  $\phi = 0,8$  e  $\theta = 0,3$  - Figura retirada de Morettin e Toloi (2006)

# Aplicação

**Aplicação no *software* R.**



# Função de autocorrelação parcial

Como visto anteriormente, os processos  $AR(p)$ ,  $MA(q)$  e  $ARMA(p, q)$  apresentam FAC com características especiais. Assim

- (i) um processo  $AR(p)$  tem FAC que decai de acordo com exponenciais e/ou senóides amortecidas, infinita em extensão;
- (ii) um processo  $MA(q)$  tem FAC finita, no sentido que ela apresenta um corte após “lag”  $q$ ;
- (iii) um processo  $ARMA(p, q)$  tem FAC infinita em extensão, a qual decai de acordo com exponenciais e/ou senóides amortecidas após o “lag”  $q - p$ .

# Função de autocorrelação parcial

Estas observações serão úteis no procedimento de identificação do modelo aos dados observados; calculando-se as estimativas das FAC, que acreditamos reproduzir adequadamente as verdadeiras FAC desconhecidas e comparando seu comportamento com o descrito acima, para cada modelo, tentaremos escolher um (ou mais) modelo (modelos, respectivamente) que descreva(m) o processo estocástico.

Box, Jenkins e Reinsel (1994) propõem a utilização de um outro instrumento para facilitar este processo de identificação: a *função de autocorrelação parcial* (FACP).

# Função de autocorrelação parcial

Vamos denotar por  $\phi_{kj}$  o  $j$ -ésimo coeficiente de um modelo  $AR(k)$ , de tal modo que  $\phi_{kk}$  seja o último coeficiente. Sabemos que

$$\rho_j = \phi_{k1}\rho_{j-1} + \phi_{k2}\rho_{j-2} + \dots + \phi_{kk}\rho_{j-k}, \quad j = 1, \dots, k,$$

A quantidade  $\phi_{kk}$ , encarada como função de  $k$ , é chamada *função de autocorrelação parcial*.

# Função de autocorrelação parcial

Pode-se demonstrar (veja Box, Jenkins e Reinsel, 1994) que, para os processos estudados, temos:

- (i) Um processo  $AR(p)$  tem FACP  $\phi_{kk} \neq 0$ , para  $k \leq p$  e  $\phi_{kk} = 0$ , para  $k > p$ ;
- (ii) Um processo  $MA(q)$  tem FACP que se comporta de maneira similar à FAC de um processo  $AR(p)$ , formada por exponenciais e/ou senóides amortecidas;
- (iii) Um processo  $ARMA(p, q)$  tem FACP que se comporta como a FACP de um processo MA puro.

# Identificação de modelos ARMA

O objetivo da identificação é determinar os valores de  $p$  e  $q$  do modelo  $\text{ARMA}(p, q)$ , além de estimativas preliminares dos parâmetros a serem usadas no estágio de estimação.

Identificar o processo  $\text{ARMA}(p, q)$  resultante, através da análise das autocorrelações e autocorrelações parciais estimadas, cujos comportamentos devem imitar os comportamentos das respectivas quantidade teóricas. Estes comportamentos, para modelos AR, MA e ARMA, foram abordados anteriormente.

# Identificação de modelos ARMA

<b>Ordem</b>	(1, 0)	(0, 1)
comportamento de $\rho_k$	decai exponencialmente	somente $\rho_1 \neq 0$
comportamento de $\phi_{kk}$	somente $\phi_{11} \neq 0$	decaimento exponencial dominante
região de admissibilidade	$-1 < \phi < 1$	$-1 < \theta < 1$
<b>Ordem</b>	(2, 0)	(0, 2)
comportamento de $\rho_k$	mistura de exponenciais ou ondas senóides amortecidas	somente $\rho_1 \neq 0$ e $\rho_2 \neq 0$
comportamento de $\phi_{kk}$	somente $\phi_{11} \neq 0$ e $\phi_{22} \neq 0$	dominada por mistura de exponenciais ou senóides amortecidas
região de admissibilidade	$\begin{cases} -1 < \phi_2 < 1 \\ \phi_2 - \phi_1 < 1 \\ \phi_2 + \phi_1 < 1 \end{cases}$	$\begin{cases} -1 < \theta_2 < 1 \\ \theta_2 - \theta_1 < 1 \\ \theta_2 + \theta_1 < 1 \end{cases}$
<b>Ordem</b>	(1,1)	
comportamento de $\rho_k$	decai exponencialmente após o lag 1	
comportamento de $\phi_{kk}$	dominada por decaimento exponencial após o lag 1	
região de admissibilidade	$-1 < \phi < 1$ e $-1 < \theta < 1$	

**Tabela 1:** Comportamento da FAC e admissibilidade em modelos ARMA

# Identificação de modelos ARMA

Também podemos fazer o uso de critérios já conhecidos para selecionar a ordem do modelo, os critérios mais utilizados são:

- $AIC := -2l(\theta) + 2k,$
- $BIC := -2l(\theta) + k\log(N),$
- $AIC_c := AIC + \frac{2k(k+1)}{N-k-1},$

sendo que  $l(\theta)$  é o valor do máximo da log-verossimilhança,  $k$  é a quantidade de parâmetros do modelo e  $N$  é o tamanho da série temporal

# Aplicação

**Aplicação no *software* R.**



# Diagnóstico de modelos ARMA

Após estimar o(s) modelo(s) temos que verificar se ele representa, ou não, adequadamente os dados.

A verificação é feita analisando os resíduos. Se o modelo ajustado for adequado, os resíduos obtidos da modelagem constituirão um ruído branco.

Qualquer desvio observado pode sugerir um modelo alternativo como sendo adequado.

# Diagnóstico de modelos ARMA

A forma mais simples e prática é a inspeção visual dos resíduos, fazendo o uso dos seguintes gráficos dos resíduos:

- gráfico dos resíduos ao longo do tempo: deve parecer um ruído aleatório;
- FAC dos resíduos: deve estar dentro dos limites de confiança;
- FACP dos resíduos: deve estar dentro dos limites de confiança.

# Teste de Box-Pierce

Box e Pierce (1970) sugeriram um teste para as autocorrelações dos resíduos estimados, que, apesar de não detectar quebras específicas no comportamento de ruído branco, pode indicar se esses valores são muito altos.

Uma variação desse teste foi sugerida por Ljung-Box (1978).

Em ambos os testes, verifica-se os resíduos têm autocorrelação significativa a partir das hipóteses

$H_0$  : os resíduos são ruído branco (sem autocorrelação), versus

$H_1$  : os resíduos têm autocorrelação.

# Previsão com modelos ARMA

Até o momento já passamos pelos ciclo iterativo de identificação, estimação e diagnóstico. Agora o objetivo é utilizar o modelo identificado, estimado e validado para fazer previsões.

Estamos interessados em prever um valor  $Z_{t+h}$ , com  $h \geq 1$ , supondo que temos observações  $\dots, Z_{t-2}, Z_{t-1}, Z_t$ , até o instante  $t$ , que é chamado origem das previsões. A previsão de origem  $t$  e horizonte  $h$  será denotada por  $\hat{Z}_t(h)$ .

A formulação matemática para as previsões é um pouco complexa, por isso vamos utilizar de rotinas já programadas para realizar as previsões.

# Aplicação

**Aplicação no *software* R.**

# Especialização em *Data Science* e Estatística Aplicada

## Módulo IV - Análise de Séries Temporais

Prof. Dr. Eder Angelo Milani

[edermilani@ufg.br](mailto:edermilani@ufg.br)

**IME**

INSTITUTO DE  
MATEMÁTICA E  
ESTATÍSTICA

**FEN**

FACULDADE DE  
ENFERMAGEM



**UFG**

UNIVERSIDADE  
FEDERAL DE GOIÁS

